



贾志刚

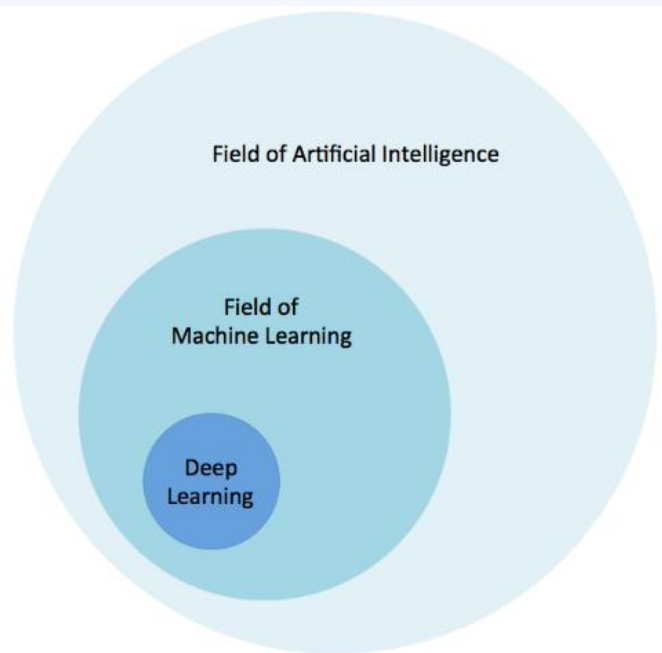
深度学习-CNN与RNN



主要内容

- 深度学习的历史
- 深度学习的应用领域
- 卷积神经网络
- 循环神经网络
- 基于卷积神经网络数字识别


深度学习的历史




机器学习的历史



深度学习/神经网络发展历史



深度学习几个要素



算法 – 模型

- 知识系统
- 专家系统
- 机器学习
- 神经网络
- 深度学习

硬件 – 算力

- CPU
- GPU
- TPU
- NPU
- IPU

存储 – 数据

- 大数据清洗处理
- 非关系型数据库
- 各种文本与图像
- 各种视频数据



Geoffrey Hinton
(Toronto)





Yann Lecun (NYU)



Yoshua Bengio
(UdeM)



Andrew Ng (Stanford)



深度学习的应用领域

- 图像分类
- 图像对象检测与识别
- 图像分割
- 图像标注
- 姿态评估
- 图像生成
- 图像修复与重建
- 风格迁移

分类



CAT


分类+定位



CAT

单个对象

对象检测



CAT, DOG, DUCK


实例分割




CAT, DOG, DUCK

多个对象

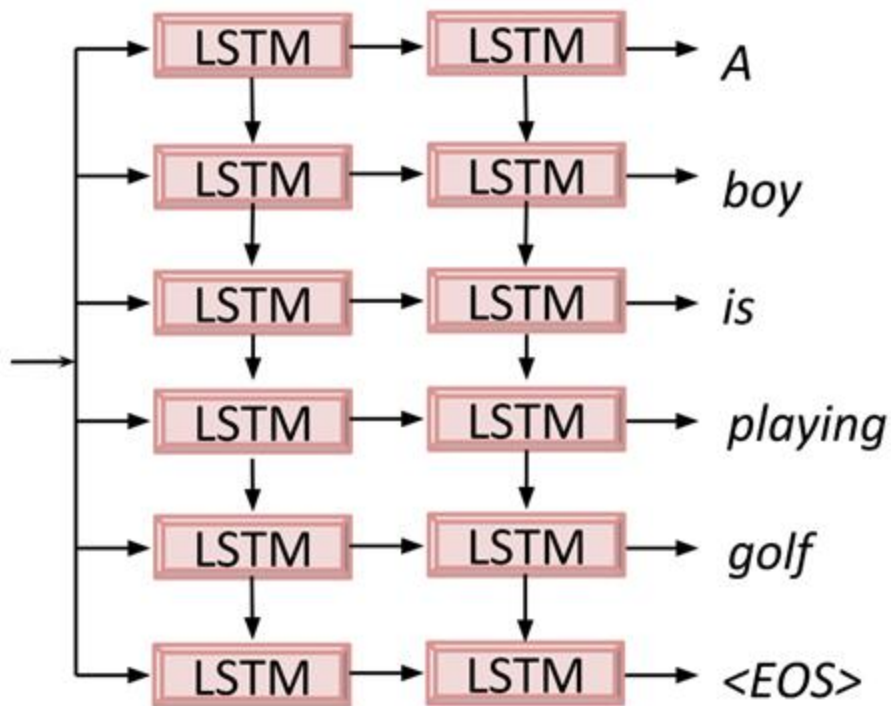
输入视频




卷积网络



循环神经网络




输出语句



<http://t.cn/RnZ38uB?m=4217785863560097&u=1242677540>

我不是梵高，我是AI

-CNN风格迁移网络
-模拟艺术风格



应用领域 – 创作

清华大学团队 使用深度学习技术 实现诗歌自动生成
为你写诗 在线尝试 - <http://poem.bosonnlp.com/>

阿里 **鲁班** AI设计 – 1秒中设计8000张海报 自动生成
一天完成4000万张 双11 海报设计

为你设计 演示视频 - <https://v.qq.com/iframe/preview.html?vid=t0398cx2tro&>




艺术领域：

莎士比亚 风格的歌剧、 莫扎特风格的谱曲

卷积神经网络

- 感知器
- 多层感知器
- 反向传播算法
- 卷积神经网络

生物学神经元



BNN – 生物神经网络

Soma(细胞体)

Dendrites(树突)

Synapse(突触)

Axon(轴突 (神经细胞的突起, 将信号发送到其他细胞))

ANN – 人工神经网络


节点

输入

权重连接

输出

感知器




单层感知器-逻辑门

NOT	
in	out
0	1
1	0

AND		
in ₁	in ₂	out
0	0	0
0	1	0
1	0	0
1	1	1

OR		
in ₁	in ₂	out
0	0	0
0	1	1
1	0	1
1	1	1



单层感知器-逻辑门

在二维平面 存在


$$I_1 \cdot w_1 + I_2 \cdot w_2 - \theta = 0$$

可以变换为如下：

$$I_2 = \frac{\theta}{w_2} - \frac{w_1}{w_2} I_1$$


AND		
I_1	I_2	out
0	0	0
0	1	0
1	0	0
1	1	1

AND
 $w_1=1, w_2=1, \theta=1.5$



OR		
I_1	I_2	out
0	0	0
0	1	1
1	0	1
1	1	1

OR
 $w_1=1, w_2=1, \theta=0.5$



单层感知器 - 代码实现



```
5 x = np.array([
6     [0, 0],
7     [1, 0],
8     [0, 1],
9     [1, 1]
10 ])
11
12 y = np.array([0, 0, 0, 1])
13 w = np.random.random(2)
```

```
15 # 学习率
16 lr = 0.11
17 n = 0
18 # 输出值
19 out = 0
20
21
22 def update():
23     global x, y, w, lr, n
24     n += 1
25     out = np.dot(x, w.T)
26     dw = lr * (y - out.T).dot(x) / int(x.shape[0])
27     w = w + dw
28
29
30 for _ in range(1000):
31     update()
32     out = np.dot(x, w.T)
33     if (out == y.T).all():
34         break
```


单层感知器

- 单层感知器的缺陷，无法解决异或门
- 感知器无法解决非线性可分离问题


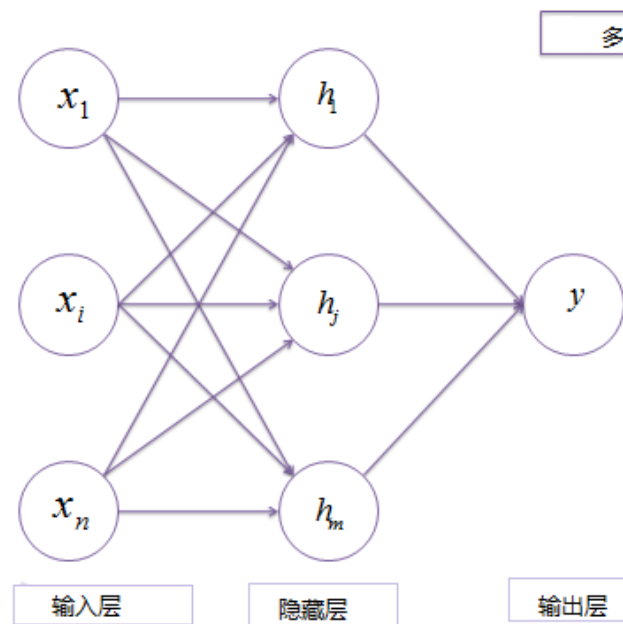
XOR		
I_1	I_2	out
0	0	0
0	1	1
1	0	1
1	1	0



单层感知器

- 单层感知器无法解决复杂任务
- 手工创建网络代价高昂
- 非线性特征也是手工生成
- 需要一种对数据自适应的原生模型
- 前馈传播网络 - MLP (multi layer perceptron)

多层感知器



求和

$$s = \sum w \cdot x$$

激活/变换

$$f(s) = \frac{1}{1 + e^{-s}}$$

多层感知器解决异或问题

解决异或问题


输入层 2个节点

隐藏层 2个节点

输出层 1个节点

期望输出

x1	x2	o1	o2	y
0	0	0	0	0
1	0	0	1	1
0	1	0	1	1
1	1	1	1	0



权重：

$$w_{11} = w_{12} = 1$$




$$w_{21} = w_{22} = 1$$

$$w_{01} = 3/2; w_{02} = 1/2; w_{03} = 1/2$$

$$w_{13} = -1; w_{23} = 1$$


多层感知器

单个/单层感知器，线性分离
二层感知器组合可以分离
三层感知器任何复杂可分



多层感知器网络特征

- 同一层内的节点相互没有连接
- 输入与输出层不直接相连
- 层与层之间的连接方式是全连接
- 经常超过三层
- 输出的节点单元不必与输入节点单元数目相等
- 隐藏层的节点单元数目可以大于或者少于输入/输出层




每个节点是一个感知器，通常添加增益 b 来调整权重 w

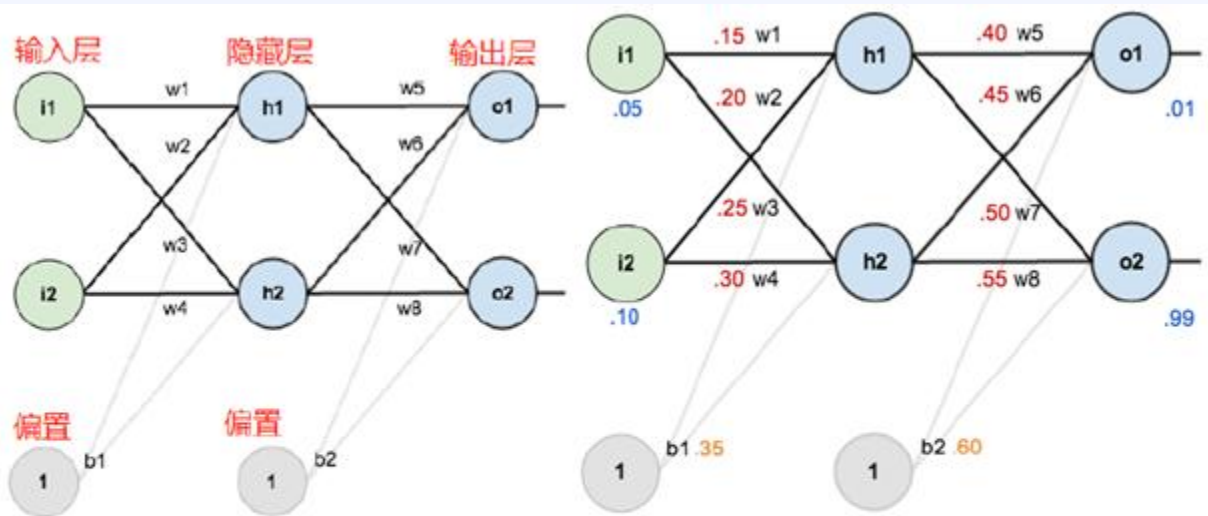
$$y_i = f\left(\sum_{j=1}^m w_{ij} x_j + b_i\right)$$

多层感知器学习 – 反向传播算法

- 前馈网络与反馈网络
- BP算法的两个阶段
 - 前向传播阶段
 - 反向传播阶段



反向传播算法 - 前向传播



$$net_{h1} = w_1 i_1 + w_2 i_2 + b_1 = 0.15 * 0.05 + 0.2 * 0.1 + 0.35 = 0.3775$$

$$net_{o1} = w_5 outh_1 + w_6 outh_2 + b_2 = 0.4 * 0.5932699 + 0.45 * 0.59688 + 0.6 = 1.1059$$

$$outh_1 = \frac{1}{1 + e^{-net_{h1}}} = \frac{1}{1 + e^{-0.3775}} = 0.5932699$$

$$outh_2 = \frac{1}{1 + e^{-net_{h2}}} = 0.59688$$

$$E_{total} = \sum \frac{1}{2} (target - output)^2$$

$$E_{o1} = \sum \frac{1}{2} (target_{o1} - output_{o1})^2$$

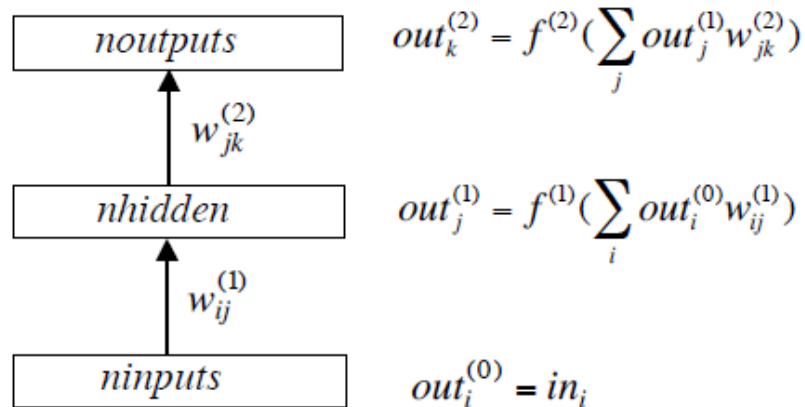
$$= \frac{1}{2} (0.01 - 0.751365)^2 = 0.274811$$

$$E_{o2} = 0.02356$$

$$E_{total} = E_{o1} + E_{o2} = 0.2983$$

$$out_{o1} = \frac{1}{1 + e^{-net_{o1}}} = \frac{1}{1 + e^{-1.1059}} = 0.7513$$

反向传播算法 - 前向传播




前向传播计算

SSE Loss (sum-squared error)

$$E_{SSE} = \frac{1}{2} \sum_p \sum_j \left(targ_j^p - out_j^{(N)p} \right)^2$$

$$E_{CE} = - \sum_p \sum_j \left[targ_j^p . \log \left(out_j^{(N)p} \right) + (1 - targ_j^p) . \log \left(1 - out_j^{(N)p} \right) \right]$$

反向传播算法 - 反向传播



$$\frac{\partial E_{\text{total}}}{\partial w_5} = -(t \arg et_{o1} - \text{out}_{o1}) * \text{out}_{o1} (1 - \text{out}_{o1}) * \text{out}_{h1} = \delta_{o1} \text{out}_{h1}$$

$$w_5^+ = w_5 - \eta * \frac{\partial E_{\text{total}}}{\partial w_5} = 0.4 - 0.5 * 0.082167041 = 0.35891648$$

η : 表示学习率

输出层: $\frac{\partial E_{\text{total}}}{\partial w_5} = \frac{\partial E_{\text{total}}}{\partial \text{out}_{o1}} \frac{\partial \text{out}_{o1}}{\partial \text{net}_{o1}} \frac{\partial \text{net}_{o1}}{\partial w_5}$

$$\frac{\partial E_{\text{total}}}{\partial \text{out}_{o1}} = -(t \arg et_{o1} - \text{out}_{o1}) = -(0.01 - 0.751365) = 0.74136507$$

$$\frac{\partial \text{out}_{o1}}{\partial \text{net}_{o1}} = \text{out}_{o1} (1 - \text{out}_{o1}) = 0.75136507 (1 - 0.75136507) = 0.593269992$$

$$\text{out}_{o1} = \frac{1}{1 + e^{-\text{net}_{o1}}}$$

$$\text{net}_{o1} = w_5 * \text{out}_{h1} + w_6 * \text{out}_{h2} + b_2$$


$$\frac{\partial \text{net}_{o1}}{\partial w_5} = 1 * \text{out}_{h1} * w_5^{(1-1)} = \text{out}_{h1} = 0.5932$$

$$\frac{\partial E_{\text{total}}}{\partial w_5} = 0.74136507 * 0.186815602 * 0.59326992 = 0.082167041$$

$$\frac{\partial E_{total}}{\partial w_1} = \frac{\partial E_{total}}{\partial out_{h1}} * \frac{\partial out_{h1}}{\partial net_{h1}} * \frac{\partial net_{h1}}{\partial w_1}$$



$$\frac{\partial E_{total}}{\partial out_{h1}} = \frac{\partial E_{o1}}{\partial out_{h1}} + \frac{\partial E_{o2}}{\partial out_{h1}}$$




$$\frac{\partial E_{total}}{\partial w_1} = \left(\sum_o \frac{\partial E_{total}}{\partial out_o} * \frac{\partial out_o}{\partial net_o} * \frac{\partial net_o}{\partial out_{h1}} \right) * \frac{\partial out_{h1}}{\partial net_{h1}} * \frac{\partial net_{h1}}{\partial w_1}$$

$$\frac{\partial E_{total}}{\partial w_1} = \left(\sum_o \delta_o * w_{ho} \right) * out_{h1} (1 - out_{h1}) * i_1$$


$$\frac{\partial E_{total}}{\partial w_1} = \delta_{h1} i_1$$

$$\Delta w_{kl}^{(m)} = -\eta \frac{\partial E(\{w_{ij}^{(n)}\})}{\partial w_{kl}^{(m)}}$$


梯度下降 - 优化




一个全局最小化 \vec{u}^* 是一个点满足
 $f(\vec{u}^*) \leq f(\vec{u})$




$$\frac{\partial f}{\partial u_i}(\vec{u}^+) = 0 \quad \text{for all } i$$




寻找 \vec{v} 对应成立 $f(\vec{v}) < f(\vec{u})$



斜率为负值，右移




寻找 \vec{v} 对应成立 $f(\vec{v}) < f(\vec{u})$




斜率为正值，左移


学习率影响




学习率小，正常收敛



学习率过小，收敛很慢



学习率大，快速收敛





学习率过大，无法收敛

反向传播训练MLP



- 基于epoch - 所有训练样本计算一次更新
- 基于样本数 - 每个样本更新一次

激活函数-sigmoid



1. 有饱和放电区存在，导致梯度消失
2. 输出结果不是非零中心化输出
3. 指数计算

激活函数-tanh



1. 有饱和放电区存在，导致梯度消失
2. 指数计算

多层感知器的不足

- 全连接层对高维数据导致维度灾难
- 不能添加更多层数，梯度消失/梯度爆炸
- 使用tanh与sigmoid作为激活函数

多层感知器的代码演示

- mnist数据集
- Tensorflow代码实现
- 运行与测试


Mnist 数据集

- 数据集下载地址 - <http://yann.lecun.com/exdb/mnist/>
- 训练数据集 6W张图像
- 测试数据集 1W张图像
- 数据格式说明 28x28大小

Mnist数据集

数据集名称	说明
train-images-idx3-ubyte.gz	训练图像28x28大小，6万张
train-labels-idx1-ubyte.gz	每张图像的数字标记，6万条
t10k-images-idx3-ubyte.gz	测试数据集、1万张图像28x28
t10k-labels-idx1-ubyte.gz	测试数据集标记，表示图像数字

开始移位	类型	值	描述
0000	4字节int类型	0x00000803(2051)	魔数
0004	4字节int类型	60000	图像数目
0008	4字节int类型	28	图像高度
00012	4字节int类型	28	图像宽度



mnist数据集 - 神经网络

MLP网络结构

- 输入层784
- 隐藏层30
- 输出层10

实现0-9手写数字识别

定义网络静态图结构

```
hidden_nodes = 30
x = tf.placeholder(shape=[None, 784], dtype=tf.float32)
y = tf.placeholder(shape=[None, 10], dtype=tf.float32)

W1 = tf.Variable(tf.truncated_normal(shape=[784, hidden_nodes]), dtype=tf.float32)
b1 = tf.Variable(tf.truncated_normal(shape=[1, hidden_nodes]), dtype=tf.float32)

W2 = tf.Variable(tf.truncated_normal(shape=[hidden_nodes, 10]), dtype=tf.float32)
b2 = tf.Variable(tf.truncated_normal(shape=[1, 10]), dtype=tf.float32)

# layer hidden
nn_1 = tf.add(tf.matmul(x, W1), b1)
h1 = tf.nn.sigmoid(nn_1)

# output
nn_2 = tf.add(tf.matmul(h1, W2), b2)
out = tf.nn.sigmoid(nn_2)
```

定义网络静态图结构

```
# loss function
# loss = tf.reduce_sum(tf.square(tf.subtract(y, out)))
loss = tf.nn.sigmoid_cross_entropy_with_logits(logits=nn_2, labels=y)

# BP
step = tf.train.GradientDescentOptimizer(0.05).minimize(loss)
init = tf.global_variables_initializer()

# accuracy
acc_mat = tf.equal(tf.argmax(out, 1), tf.argmax(y, 1))
acc = tf.reduce_sum(tf.cast(acc_mat, tf.float32))
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    for i in range(10000):
        batch_xs, batch_ys = mnist.train.next_batch(128)
        sess.run(step, feed_dict={x: batch_xs, y: batch_ys})
        if (i+1) % 1000 == 0:
            curr_acc = sess.run(acc, feed_dict={x: mnist.test.images[:1000],
                                                y: mnist.test.labels[:1000]})
            print("current test Accuracy : %f" % (curr_acc))
```


训练结果

```
current test Accuracy : 906.000000  
current test Accuracy : 917.000000  
current test Accuracy : 921.000000  
current test Accuracy : 932.000000  
current test Accuracy : 930.000000  
current test Accuracy : 924.000000  
current test Accuracy : 931.000000  
current test Accuracy : 930.000000  
current test Accuracy : 942.000000  
current test Accuracy : 943.000000
```


卷积神经网络

- 卷积层
- 池化层
- 全连接层
- 激活函数
- 认识LeNet模型

一维离散卷积



二维离散卷积



1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved
Feature

$$M = \begin{pmatrix} m_{00} & m_{01} & m_{02} & m_{03} & m_{04} \\ m_{10} & m_{11} & m_{12} & m_{13} & m_{14} \\ m_{20} & m_{21} & m_{22} & m_{23} & m_{24} \\ m_{30} & m_{31} & m_{32} & m_{33} & m_{34} \\ m_{40} & m_{41} & m_{42} & m_{43} & m_{44} \end{pmatrix}$$

$$c = \begin{pmatrix} c_{00} & c_{01} & c_{02} \\ c_{10} & c_{11} & c_{12} \\ c_{20} & c_{21} & c_{22} \end{pmatrix}$$

$$\begin{aligned} conv(M, c)[1, 1] = & m_{11} * c_{00} + m_{12} * c_{01} + m_{13} * c_{02} + \\ & m_{21} * c_{10} + m_{22} * c_{11} + m_{23} * c_{12} + \\ & m_{31} * c_{20} + m_{32} * c_{21} + m_{33} * c_{22} \end{aligned}$$


多个滤波器 - filters





08 02 22 97 38 15 00 40 00 75 04 05 07 78 52 12 50 77 91 08
49 49 99 40 17 81 18 57 60 87 17 40 95 43 69 48 04 56 62 00
81 49 31 73 55 79 14 29 93 71 40 67 53 88 30 03 49 13 36 65
52 70 95 23 04 60 11 42 69 24 68 56 01 32 56 71 37 02 36 91
22 31 16 71 51 67 63 89 41 92 36 54 22 40 40 28 66 33 13 80
24 47 32 60 99 03 45 02 44 75 33 53 78 36 84 20 35 17 12 50
32 98 81 28 64 23 67 10 26 38 40 47 59 34 70 66 18 38 64 70
67 26 20 68 02 62 12 20 95 43 94 39 63 08 40 91 66 49 94 21
24 55 58 05 66 73 99 26 97 17 78 78 96 83 14 88 34 89 63 72
21 36 23 09 75 00 76 44 20 45 35 14 00 61 33 97 34 31 33 95
78 17 53 28 22 75 31 47 15 94 03 80 04 62 16 14 09 53 56 92
16 39 05 42 96 35 31 47 55 58 88 24 00 17 54 24 36 29 85 57
86 56 00 48 35 71 89 07 05 44 44 37 44 40 21 58 51 54 17 58
19 80 81 68 05 94 47 69 28 73 92 13 86 32 17 77 04 89 55 40
04 52 08 83 97 35 99 16 07 97 57 32 16 26 26 79 33 27 98 66
88 36 68 87 57 62 20 72 03 46 33 67 46 35 12 32 63 93 53 69
04 42 16 73 38 25 39 11 24 94 72 18 08 46 29 32 40 62 76 36
20 69 36 41 72 30 23 88 34 62 99 69 82 47 59 85 74 04 36 16
20 73 35 29 78 31 90 01 74 31 49 71 48 86 81 16 23 57 05 54
01 70 54 71 83 51 54 69 16 92 33 48 61 43 52 01 89 19 67 48



Input image




Filter bank (to be learned)



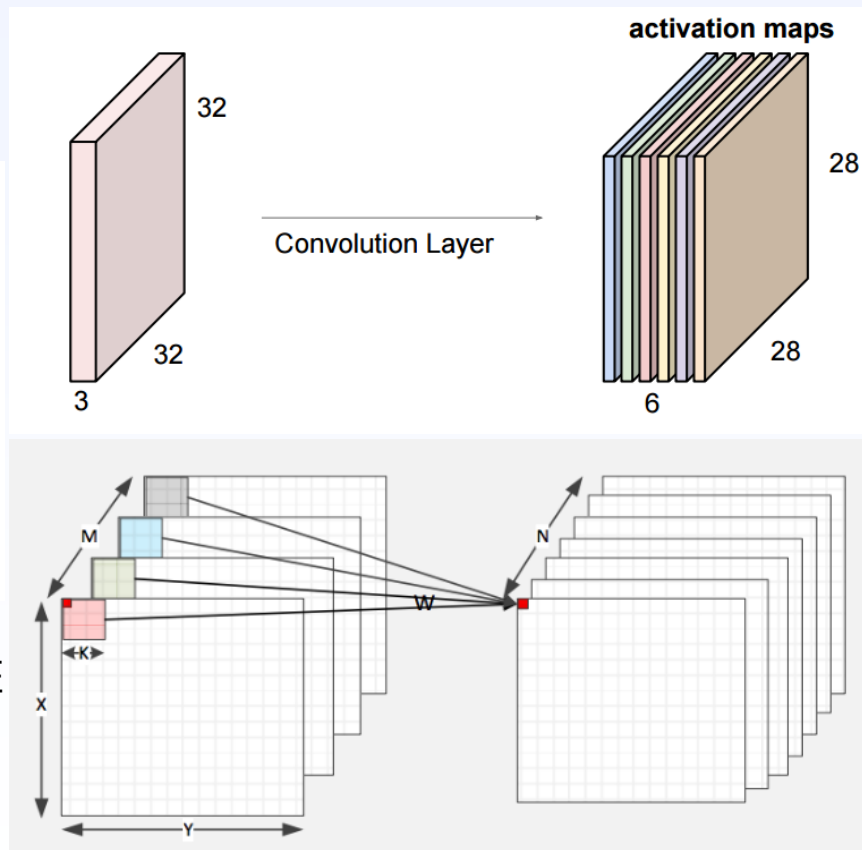
Feature maps

卷积层详解





5x5的卷积，产生一个新的像素点，通过激活函数，产生

1. 减少了参数总数，降低了计算量
2. 通过filter maps提取特征，保证图像空间特征与结构。



池化层详解

1. 均值池化
2. 最大值池化




全连接层


- 多层感知器组合
- 能力不够强大???
- 多个隐藏层 与 隐藏层包含足够多的神经元 -》难以训练，过拟合 -》早停法
- 事实证明 增加深度比宽度有效

多层感知器与 dropout


- 神经网络（多层感知器MLP）
- dropout




标准神经网络



带 dropout 的神经网络



部分节点权重训练



全部节点参与测试，前向网络




作用：防止过拟合，增加了神经网络的训练层数

基本激活函数

$$\text{threshold}(x) = \begin{cases} 1 & \text{if } x \geq 1 \\ 0 & \text{if } x < 1 \end{cases}$$


$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$




激活函数 - 更多

$$\text{ReLU} = f(x_j^i) = \max(0, x_j^i)$$



缺点：死亡ReLU

$$\text{Leaky ReLU} = f(x_j^i) = \max(0.01x_j^i, x_j^i)$$




Leaky ReLU


$$f(x) = \max(0.01x, x)$$

1. 快速收敛
2. 不会死亡
3. 计算简单，相比sigmoid
4. 不会饱和

$$\text{Smooth ReLU} = f(x_j^i) = \log(1 + \exp(x_j^i))$$



克服缺点，不会死亡




- 输入层(Input Layer)表示输入数据 (图像)
- 卷积层(Convolution Layer)通过 5×5 的卷积核实现特征提取，然后通过 2×2 大小最大池化，降采样。上图有两个卷积层
- 全连接层(Full connection Layer)，传统神经网络的多层感知器(MLP)。上图有两个全连接层
- 输出层(Output Layer)

卷积神经网络-代码实现与演示


- CNN网络构建
- Mnist数据
- 训练与测试

循环神经网络-RNN

- CNN当前节点的输入以树结构形式仅包含上一层节点信息
- RNN当前节点的输入包含之前所有节点信息
- RNN可以解决序列预测问题



循环神经网络-基本原理



x_t 表示 t 时刻的输入

s_t 表示 t 时刻的隐藏状态，是RNN的记忆存储 $s_t = f(Ux_t + W_{s_{t-1}})$

o_t 时刻的序列预测 $o_t = \text{soft max}(V_{s_t})$


循环神经网络RNN-应用领域

- 语言模型与文本生成
- 机器翻译
- 语音识别
- CNN+RNN图像描述


循环神经网络RNN训练方法

- BPTT (Backpropagation Through Time)
- 对过长的序列训练会很困难
- 容易导致梯度消失与梯度爆炸问题
- RNN模型扩展 - 双向RNN/深度RNN


循环神经网络-经典模型LSTM (Long Short Term Memory networks)




标准的RNN单元



标准的LSTM单元




循环神经网络-经典模型LSTM (Long Short Term Memory networks)




1 - 表示通过
0 - 表示不通过

输入门




$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$




$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

遗忘门



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

传送门



$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t * \tanh(C_t)$$

输出门

课程问题咨询微信





Thank You !